



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика, искусственный интеллект и системы управления

КАФЕДРА Системы обработки информации и управления

ОТЧЕТ

по Лабораторной работе № 1

по дисциплине «**МЕТОДЫ МАШИННОГО ОБУЧЕНИЯ**»

Тема: «**Обработка признаков (часть 1)**»

Студент	<u>ИУ5И-22М</u>	<u></u>	<u>Тавуз Мохамад</u>
	(группа)	(подпись, дата)	(И.О. Фамилия)
Преподаватель		<u></u>	<u>Ю.Е.Гапанюк</u>
		(подпись, дата)	(И.О. Фамилия)

2026 г.

1) Введение

Предварительная обработка данных является важным этапом при построении моделей машинного обучения.

Цель данной лабораторной работы — изучение и применение методов обработки данных, включая проверку и заполнение пропущенных значений, кодирование категориальных признаков и нормализацию числовых данных.

В ходе работы были использованы реальные данные из набора Titanic для демонстрации этих методов на практике.

О наборе данных Titanic:

- Название набора данных**: Titanic Dataset
- Источник: [Data Science Dojo Titanic dataset](<https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv>)
- Количество строк: 891
- Количество столбцов: 12 признаков + 1 целевая переменная
- Описание столбцов:
 - PassengerId: Идентификационный номер пассажира
 - Survived: Выжил ли пассажир (1 - да, 0 - нет)
 - Pclass: Социальный класс пассажира (1, 2, 3)
 - Name: Имя пассажира
 - Sex: Пол пассажира (мужской или женский)
 - Age: Возраст пассажира
 - SibSp: Количество братьев/сестер или супругов на борту
 - Parch: Количество родителей/детей на борту

- Ticket: Номер билета
- Fare: Стоимость билета
- Cabin: Номер каюты (может содержать пропуски)
- Embarked: Порт посадки пассажира (C, Q, S)
- Целевая переменная (y)**: **Survived** – выжил ли пассажир (0 или 1)

2) Описание задания

Задачи лабораторной работы:

1. Выбрать набор данных, содержащий числовые и категориальные признаки, а также пропуски в данных.
2. Выполнить следующие этапы обработки данных:
 - i. Устранение пропусков в данных (missing values).
 - ii. Кодирование категориальных признаков (categorical encoding).
 - iii. Нормализация числовых признаков (normalization).
3. Проанализировать результаты обработки и визуализировать изменения данных с помощью графиков.

3) Текст программы И Экранные формы с примерами выполнения

Загрузка данных и предварительный просмотр

```
import seaborn as sns

# Загрузка набора данных Titanic
df = sns.load_dataset('titanic')

# Показать первые 5 строк для предварительного просмотра данных
df.head()
```

...	survived	pclass	sex	age	sibsp	parch	fare	embarked	class	who	adult_male	deck	embark_town	alive	alone
0	0	3	male	22.0	1	0	7.2500	S	Third	man	True	NaN	Southampton	no	False
1	1	1	female	38.0	1	0	71.2833	C	First	woman	False	C	Cherbourg	yes	False
2	1	3	female	26.0	0	0	7.9250	S	Third	woman	False	NaN	Southampton	yes	True
3	1	1	female	35.0	1	0	53.1000	S	First	woman	False	C	Southampton	yes	False
4	0	3	male	35.0	0	0	8.0500	S	Third	man	True	NaN	Southampton	no	True

Рисунок 1 — Начальные данные

Проверка и обработка пропущенных значений

```
# Проверка наличия пропущенных значений в наборе данных
df.isnull().sum()
```

```
0
survived    0
pclass      0
sex         0
age        177
sibsp       0
parch       0
fare        0
embarked    2
class       0
who         0
adult_male  0
deck       688
embark_town  2
alive       0
alone       0
dtype: int64
```

Рисунок 2 — Проверка пропущенных значений в наборе данных

```

# Заполнение пропущенных значений в числовых столбцах средним
df['age'].fillna(df['age'].mean(), inplace=True)

# Заполнение пропущенных значений в категориальных столбцах модой
df['embarked'].fillna(df['embarked'].mode()[0], inplace=True)
df['embark_town'].fillna(df['embark_town'].mode()[0], inplace=True)

# Удаление столбца с большим количеством пропусков
df.drop(columns=['deck'], inplace=True)

# Проверка, что все пропущенные значения обработаны
df.isnull().sum()

```

	0
survived	0
pclass	0
sex	0
age	0
sibsp	0
parch	0
fare	0
embarked	0
class	0
who	0
adult_male	0
embark_town	0
alive	0
alone	0
dtype:	int64

Рисунок 3 — Заполнение пропущенных значений и проверка результата

```

import matplotlib.pyplot as plt

# Гистограмма возраста до заполнения пропусков
plt.figure(figsize=(12,5))
plt.subplot(1,2,1)
plt.hist(df['age'], bins=30, color='blue', alpha=0.7)
plt.title('AGE distribution AFTER filling')
plt.xlabel('Age')
plt.ylabel('Frequency')

# Для сравнения можно добавить оригинальные данные, если сохранили копию до fillna
# plt.subplot(1,2,2)
# plt.hist(age_original, bins=30, color='green', alpha=0.7)
# plt.title('AGE distribution BEFORE filling')
# plt.xlabel('Age')
# plt.ylabel('Frequency')

plt.show()

```




Рисунок 4 — Гистограмма распределения возраста после заполнения пропусков

Преобразование и кодирование категориальных признаков

```
from sklearn.preprocessing import LabelEncoder

# Преобразование булевых столбцов в числовые (0/1)
df['adult_male'] = df['adult_male'].astype(int)
df['alone'] = df['alone'].astype(int)

# One-hot кодирование для категориальных столбцов
df = pd.get_dummies(df, columns=['sex', 'embarked', 'class', 'who', 'alive'], drop_first=True)

# Показать первые 5 строк после кодирования
df.head()
```

***	survived	pclass	age	sibsp	parch	fare	adult_male	embark_town	alone	sex_male	embarked_Q	embarked_S	class_Second	class_Third	who_man	who_woman	alive_yes
0	0	3	22.0	1	0	7.2500	1	Southampton	0	True	False	True	False	True	True	False	False
1	1	1	38.0	1	0	71.2833	0	Cherbourg	0	False	False	False	False	False	False	True	True
2	1	3	26.0	0	0	7.9250	0	Southampton	1	False	False	True	False	True	False	True	True
3	1	1	35.0	1	0	53.1000	0	Southampton	0	False	False	True	False	False	False	True	True
4	0	3	35.0	0	0	8.0500	1	Southampton	1	True	False	True	False	True	True	False	False

Рисунок 5 — Кодирование категориальных признаков и результат

Нормализация и визуализация числовых признаков

```
from sklearn.preprocessing import MinMaxScaler

# Инициализация масштабировщика
scaler = MinMaxScaler()

# Выбор числовых столбцов для нормализации
numeric_cols = ['age', 'fare']

# Применение масштабирования
df[numeric_cols] = scaler.fit_transform(df[numeric_cols])

# Показать первые 5 строк после нормализации
df.head()
```

	survived	pclass	age	sibsp	parch	fare	adult_male	embark_town	alone	sex_male	embarked_Q	embarked_S	class_Second	class_Third	who_man	who_woman	alive_yes
0	0	3	0.271174	1	0	0.014151	1	Southampton	0	True	False	True	False	True	True	False	False
1	1	1	0.472229	1	0	0.139136	0	Cherbourg	0	False	False	False	False	False	False	True	True
2	1	3	0.321438	0	0	0.015469	0	Southampton	1	False	False	True	False	True	False	True	True
3	1	1	0.434531	1	0	0.103644	0	Southampton	0	False	False	True	False	False	False	True	True
4	0	3	0.434531	0	0	0.015713	1	Southampton	1	True	False	True	False	True	True	False	False

Рисунок 6 — Нормализация числовых признаков и результат

```
plt.figure(figsize=(12,5))

# Histogram для колонки age после Min-Max Scaling
plt.hist(df['age'], bins=30, color='purple', alpha=0.7)
plt.title('Histogram: age после Min-Max [0,1]')
plt.xlabel('Normalized Age')
plt.ylabel('Frequency')
plt.show()

# Histogram для колонки fare после Min-Max Scaling
plt.hist(df['fare'], bins=30, color='orange', alpha=0.7)
plt.title('Histogram: fare после Min-Max [0,1]')
plt.xlabel('Normalized Fare')
plt.ylabel('Frequency')
plt.show()
```

Рисунок 7 — Код для построения гистограмм после Min-Max нормализации




Рисунок 8 — Гистограмма возраст после Min-Max нормализации




Рисунок 9 — Гистограмма fare после Min-Max нормализации

```
import seaborn as sns

plt.figure(figsize=(12,5))
plt.subplot(1,2,1)
sns.boxplot(y=df['age'])
plt.title('Boxplot: age после нормализации')

plt.subplot(1,2,2)
sns.boxplot(y=df['fare'])
plt.title('Boxplot: fare после нормализации')

plt.show()
```




Рисунок 10 — Boxplot числовых признаков после нормализации

4) Заключение

В ходе лабораторной работы были изучены и применены основные методы предварительной обработки данных.

Были выполнены следующие задачи:

1. Проверка и обработка пропущенных значений в наборе данных.
2. Кодирование категориальных признаков с помощью One-hot encoding и преобразование булевых столбцов.
3. Нормализация числовых признаков с использованием Min-Max Scaling.
4. Визуализация изменений данных с помощью гистограмм и boxplot для наглядного анализа.

В результате подготовленные данные готовы для дальнейшего построения моделей машинного обучения.